


Ficha

Dataset

E.coli Protein



Nombre Dataset: E. coli Protein Localization Sites

Descripción: dataset donado en 1996 y disponible en el UCI Machine Learning Repository. Se utiliza para predecir el sitio de localización celular de proteínas de Escherichia coli a partir de características extraídas de sus secuencias.

Detalles Técnicos

Tipo de problema: Clasificación multiclase.

Número de ejemplos: 336

Características(Features):

- **SEQUENCE_NAME:** identificador de la secuencia.
- **MCG:** valor derivado del método de McGeoch para el reconocimiento de secuencias señal.
- **GVH:** valor obtenido mediante el método de von Heijne para el reconocimiento de secuencias señal.
- **LIP:** puntuación del consenso de la peptidasa II de lipoproteínas (atributo binario).
- **CHG:** indica la presencia de carga en el extremo N de las lipoproteínas predichas (atributo binario).
- **AAC:** puntuación obtenida de un análisis discriminante basado en el contenido de aminoácidos de proteínas de membrana externa y periplásmicas.
- **ALM1:** valor del programa ALOM para la predicción de regiones transmembrana.
- **ALM2:** valor del mismo programa ALOM tras excluir las regiones señal potencialmente clivables.

Variable(s) objetivo(s) (Target(s)):

- **SITE:** etiqueta que indica el sitio de localización de la proteína.

Origen y metodología

Fuente: UCI Machine Learning Repository
(dataset donado en 1996 por Kenta Nakai)

Método de recolección: las características fueron calculadas a partir de secuencias proteicas de E. coli utilizando métodos computacionales especializados (como el de McGeoch y von Heijne) que evalúan propiedades relevantes para el reconocimiento de secuencias señal. La información original proviene de registros en la base de datos SWISS-PROT.

Consideraciones del dataset: dataset equilibrado y con datos limpios.